

Examen Argumentativo

Juan Pablo Guzmán Segura	A01039810
Valeria Mariane Cárdenas Rodríguez	A01721814
Rodrigo Leal Torres	A00836930
Ana Karen Márquez Escobar	A01028413
Pablo Pérez Sandoval	A01710355

13 de junio de 2024

Análisis de ciencia de datos (Gpo 301)

Índice

I. Introducción.....	2
II. Comprensión del Negocio.....	3
III. Comprensión de los Datos.....	4
A. Análisis Exploratorio de Datos (EDA).....	5
B. Data Cleaning.....	17
C. Data Engineering.....	18
IV. Modelado.....	25
A. Modelo de Árboles de decisión.....	25
B. Metodología.....	25
a. Experimentos.....	26
b. Métricas de desempeño.....	32
C. Resultados.....	32
a. Resultados generales.....	32
b. Selección y validación cruzada del mejor modelo.....	33
V. Evaluación del modelo seleccionado.....	34
A. Análisis de desempeño.....	35
B. Análisis de características importantes.....	37
C. Implicaciones y limitaciones del modelo y su uso.....	38
VI. Conclusiones.....	40
VII. Referencias.....	41
VIII. Anexos.....	42

I. Introducción

El Instituto Nacional de Estadística y Geografía (INEGI) es un organismo público del gobierno de México encargado de generar, recopilar, procesar y difundir información estadística y geográfica. Sus funciones principales incluyen la realización de censos y encuestas, la creación de estadísticas y la elaboración de bases de datos con información geográfica y ambiental. Uno de los censos más relevantes que realiza el INEGI es el censo nacional de vivienda y población. En este censo se recopilan características demográficas, socioeconómicas y culturales de los habitantes mexicanos (INEGI, 2020). A través de esta información, se realizan bases de datos y análisis estadísticos con el propósito de tomar decisiones que mejoren el bienestar de la población.

La importancia del INEGI radica en su capacidad para proporcionar datos fundamentales para la formulación de políticas públicas y la toma de decisiones informadas en todos los niveles de gobierno. Al facilitar el acceso a estadísticas económicas detalladas y actualizadas, el INEGI promueve la transparencia y la rendición de cuentas, y contribuye significativamente al desarrollo económico y social de México. El trabajo realizado por el INEGI es esencial para la comunidad mexicana, sin embargo, en la era tecnológica se han enfrentado a varios problemas que les ha dificultado su desarrollo. Uno de sus principales problemas se relaciona a la lentitud y dificultad de acceso a la información en su página web. El buscador contenido en esta página, carece en el procesamiento de la información para poder arrojar un resultado certero de lo que el usuario desea. La estructura de la página web del INEGI tiene varias áreas de oportunidad ya que encontrar bases de datos no es tan sencillo.

Este reporte tiene como objetivo explorar y analizar los factores relevantes para determinar si una persona percibe ingresos por encima o debajo de un determinado umbral salarial. Mediante la aplicación de métodos estadísticos y análisis de los datos proporcionados por el INEGI, buscamos confirmar nuestra hipótesis para proporcionar recomendaciones que puedan ser utilizadas en futuras decisiones estratégicas, aumentando la comprensión de las variables económicas y demográficas que afectan los ingresos de los habitantes del país de México.

II. Comprensión del Negocio

Para comprender los objetivos que comprende el Instituto Nacional de Estadística y Geografía (INEGI), es importante entender que es una institución gubernamental en México que se encarga de recopilar, procesar y difundir información estadística, geográfica y económica a nivel nacional y por entidad. Además, proporciona datos sobre indicadores sociodemográficos y económicos por área geográfica, como la escolaridad de la población, el habla de lenguas indígenas, entre otras cosas.

Sin embargo, el tener una inmensa cantidad hace que el problema de organización sea complejo y en ocasiones confuso. Mediante la visualización de la página y el análisis de los datos comprendemos que la institución cuenta con una serie de necesidades primordiales para manejar la información y los recursos eficientemente. Entre estas necesidades se encuentra la implementación de sistemas avanzados de gestión de datos que permitan un almacenamiento, recuperación y análisis efectivo. Además, consideramos que la interfaz de la plataforma requiere varias mejoras que faciliten el acceso, comprensión y navegación de los datos por parte de los usuarios. Por otro lado, determinamos indispensable la capacitación continua del personal en técnicas de manejo de bases de datos y análisis estadístico, manteniendo así la calidad y la relevancia de la información.

A partir de estas necesidades, el equipo de trabajo seleccionó una como la más importante: el análisis de los datos. El proceso se centra en la capacidad de interpretar la cantidad de información recolectada, transformándola en insights útiles para la toma de decisiones. Este aspecto no solo mejora la precisión y la profundidad del análisis, sino que también ayuda a que el INEGI pueda darse cuenta de la importancia de proporcionar los datos necesarios de una forma accesible.

III. Comprensión de los Datos

A través de la página web del INEGI, se obtuvieron los conjuntos de datos de la Encuesta Nacional de Ingresos y Gastos de los Hogares (ENIGH) realizada en el año 2022. Los conjuntos de datos se relacionan a características de la población, vivienda, ingresos, gastos, consumo agrónomo y trabajo. En total, se descargaron 17 bases de datos, sin embargo, solo se eligieron dos bases de datos con el fin de analizar la relación entre las características de una persona con su ingreso. Los conjuntos de datos seleccionados contienen las características de la población relacionadas a vivienda y trabajo, así como las características relacionadas al ingreso de cada integrante. Para poder realizar un mejor análisis, se integraron las bases de datos para obtener un conjunto de datos con 192 características. Además, con el fin de facilitar el manejo de los datos, se seleccionaron las variables que se consideraron más relevantes para el ingreso de una persona, reduciendo la base de datos a 23 columnas. Para esta selección de variables, se graficó el comportamiento individual de cada una y posteriormente se realizó una matriz de correlación para verificar si la variable era relevante para el estudio. La base de datos contiene variables como el folio de cada participante en el censo, su sexo, edad, si es padre o madre, entidad en donde reside y varias características más. Además, le adjuntamos dos variables al final: ingreso trimestral total e ingreso trimestral máximo.

La nueva base de datos contiene 309,684 filas dentro de ella, haciendo alusión a que esa cantidad de personas participaron en el censo. Analizando preliminarmente la edad en relación con el ingreso total trimestral, encontramos que el promedio de edad en nuestros datos es de 33.27 años, mientras que el ingreso trimestral total promedio es de \$23,686.18 pesos mexicanos. La edad mínima registrada es de 0 años y el ingreso más bajo es de \$0.97 pesos, lo que podría sugerir la presencia de trabajadores informales en la muestra, así como valores irregulares. Los valores máximos muestran que la edad más alta es de 109 años y el ingreso trimestral más alto es de \$6,854,754.09 pesos. Observamos que los ingresos tienden a concentrarse alrededor del promedio, y la mayoría de las edades están en el rango de 25 a 35 años.

A. Análisis Exploratorio de Datos (EDA)

En el censo del INEGI realizado para la encuesta ENIGH en el 2022, se obtuvieron 17 bases de datos con información relacionada a los ingresos y los gastos de las personas en México. Dentro de estas, se eligió la base de datos de población (que describe la situación de vivienda, salud y características personales) con 188 variables y la base de datos de ingreso (que explica características y cifras relacionadas al ingreso y trabajo) con 18 variables. Para un mejor estudio, se mezclaron estas dos bases y se obtuvo una nueva base con 192 variables.

Dentro de la base hay datos categóricos de tipo objeto, como el folio de identificación, preguntas relacionadas al tema de salud y hospitalización, así como preguntas de uso de tiempo libre. Además, la base tiene varios datos numéricos para representar ciertas características que usualmente serían de tipo string. Por ejemplo, en el caso del sexo se representa con uno o dos, y así para preguntas de discapacidades, escolaridad, atención médica, entidad, entre otras. Por otro lado, hay variables numéricas como edad y cantidad de horas o tiempo en un actividad que representan la respuesta explícitamente.

Análisis univariado

Se llevó a cabo un análisis univariado para entender la naturaleza particular de diversas variables en el dataset. De esta forma se logra tener una base sólida para llevar a cabo análisis más complejos, permitiendo la toma de decisiones informadas sobre el tratamiento y la interpretación de los datos. Para el análisis univariado de nuestra base de datos se consideraron cuatro variables: sexo, ingreso trimestral total, entidad y edad.

Primeramente, se graficó la distribución de ambos sexos (*Gráfico 1*). El gráfico exhibe claramente al sexo femenino (barra morada) como el predominante entre los encuestados. Específicamente, se tienen 102,298 registros masculinos y 115,077 registros femeninos; lo que implica una diferencia de casi 13,000 registros.




Gráfico 1. Distribución de sexo

En cuanto al ingreso trimestral total, se optó por crear una nueva variable a partir de esta para hacer una distinción entre datos con ingreso mayor o igual a \$25,000 MXN y menor a él. Dicha variable se nombró ‘umbral’ y se utiliza para el análisis bivariado. La distribución del umbral se observa en el *Gráfico 2*.




Gráfico 2. Distribución del umbral de ingreso trimestral

En el gráfico anterior se observa que una gran mayoría de los datos, el 70.9%, corresponden a los ingresos trimestrales menores a 25k, mientras que el 29.1% restante tiene ingresos iguales o superiores a 25k. Esta distribución indica que la mayoría de los individuos en el conjunto de datos se encuentran en un rango de ingresos relativamente bajo. Esta tendencia es consistente con el ingreso promedio y el salario mínimo en nuestro país, lo que sugiere que los datos reflejan de manera precisa la realidad económica de la población estudiada.

De igual manera, se realizó un gráfico para reflejar la distribución de encuestados por entidad (*Gráfico 3*). Se observa una variedad en las respuestas, con una distribución relativamente uniforme a través de las distintas entidades. Sin embargo, se destacan algunos estados con una mayor cantidad de encuestados. Las entidades con el mayor número de encuestados son Baja California, Coahuila, Chihuahua, Guanajuato, Nuevo León, Querétaro, Sinaloa y Yucatán.




Gráfico 3. Distribución de encuestados por entidad

Destaca que varios de los encuestados pertenecen a estados del norte del país, mientras que hay muy pocos encuestados de estados del sur. Esta distribución desigual podría sesgar los datos, ya que los encuestados no se distribuyen equitativamente a lo largo de la república mexicana. Como

resultado, las características de vivienda y trabajo relacionadas con el salario podrían no ser completamente representativas de toda la población mexicana.

Para analizar la distribución de edades de los encuestados, se realizaron dos gráficos. El primero es un histograma (*Gráfico 4*) que muestra la distribución de edades de los encuestados mayores o iguales a 18 años. Dada la gran variedad de edades, se decidió realizar un segundo gráfico (*Gráfico 5*) donde se agrupan las edades en rangos de 10 años, desde los 18 hasta los 109 años, con el fin de analizar mejor los datos.




Gráfico 4. Histograma de edades (mayores o iguales a 18 años)




Gráfico 5. Distribución de edades mayores o igual es a 18 años y agrupadas por 10 años

En ambos gráficos, se observa que los datos están concentrados principalmente entre los 18 y 49 años, siendo el grupo de 18 a 29 años el que tiene la mayor cantidad de respuestas. Esto indica que nuestra base de datos tiene una mayor representación de personas menores de 40 años. Esta distribución es beneficiosa para nuestro análisis del umbral de ingresos económicos, ya que las personas en este rango de edad suelen estar en plena actividad laboral, contribuyendo significativamente al empleo y al ingreso. La mayoría de la fuerza laboral y las personas que generan ingresos económicos se encuentran entre los 18 y 60 años, lo que hace que estos datos sean relevantes y útiles para nuestro estudio.

Análisis bivariado

El siguiente paso fue hacer un análisis bivariado para tener una mejor comprensión de los fenómenos que se están estudiando. En este análisis se relacionan diversas variables con el umbral de ingreso establecido. La selección de estas variables se hizo con base en el criterio del equipo sobre cuáles creemos que se relacionan directamente con el ingreso trimestral total. Se seleccionaron 23 variables, no obstante, solamente se explicarán a detalle las cinco variables que más relación tienen con la variable objetivo. Estas cinco variables destacaron en el análisis de

correlación que se hizo posteriormente pero, por sencillez, se hace la distinción desde este punto. Asimismo, es importante destacar que este análisis se hace con datos normalizados. Dicho esto, primero se analiza la relación de la variable sexo con el umbral de ingresos.




Gráfico 6. Frecuencia de sexo por umbral de ingreso

El *Gráfico 6* presenta la distribución de ingresos en función del sexo, es decir, se muestran las proporciones de cada grupo en relación con los umbrales de ingresos establecidos (<25k y >=25k). La gráfica sugiere que los individuos del sexo masculino (sexo 1) son más propensos a tener ingresos superiores a 25k en comparación con los del sexo femenino (sexo 2). Esto podría indicar una disparidad en los ingresos entre sexos dentro de la base de datos, donde los hombres tienen una mayor representación en el rango de ingresos más altos. Esta diferencia podría deberse a varios factores, incluyendo diferencias en tipo de empleo, acceso a oportunidades laborales, entre otros.

Similarmente, se examina la proporción de individuos con ingresos menores y mayores a 25k por entidad federativa. El *Gráfico 7* sugiere una disparidad en los ingresos entre las diferentes entidades federativas. Mientras que la mayoría de las entidades tienen una mayor proporción de individuos con ingresos menores a 25k, algunas entidades destacan por tener una proporción relativamente alta de individuos con ingresos mayores a 25k, como es el caso de Baja California y Baja California Sur. Esta información es crucial para entender las dinámicas

económicas regionales y podría ser útil para diseñar políticas que aborden las desigualdades económicas a nivel estatal.




Gráfico 7. Frecuencia de entidades por umbral de ingreso

También se visualiza esta distribución con respecto a la edad, la cual se dividió en rangos de edad iguales a los antes mencionados. De esta forma es posible observar qué tan propenso es cada rango de edad a ganar más o menos ingresos con respecto al umbral establecido.




Gráfico 8. Frecuencia de rango de edad por umbral de ingreso

Como se pudo ver nuestros datos entre 30 a 99 años va en aumento la cantidad de proporcionalidad de ingreso superior a nuestro umbral. Entonces nuestros usuarios después de los 30 años entre más edad tengan en más probable el que tengan un ingreso menor a nuestro umbral de \$25,000. Pero podemos ver que en nuestro primer rango de edades ya trabajadores es más probable que se gane un ingreso mayor a el umbral con respecto al rango entre 30 a 39.

El *Gráfico 9* muestra el nivel de ingreso correspondiente al nivel escolar aprobado. Se observa que los primeros dos grados: ninguno (0) y preescolar (1), son bastante propensos a ganar menos de \$25,000, sin embargo, existe la posibilidad de poder tener un ingreso mayor a este umbral. En los siguientes niveles: primaria (2), secundaria (3), preparatoria o bachillerato (4), carrera técnica o comercial (6), y profesional (7) vemos cómo se va incrementando el porcentaje de de personas que ganan más de \$25,000. El incremento se ve paulatino entre los niveles y en el último que es el de profesional, se alcanza hasta un 50-50 entre los que ganan más o menos de \$25,000. Por otro lado, en los niveles: normal (5), maestría (8) y doctorado (9), se ve una disparidad mayor y se muestra que la mayoría gana más de \$25,000.




Gráfico 9. Frecuencia de nivel de estudio por umbral de ingreso

En el *Gráfico 10* se representa a las personas que no laboran. Se muestra que en general, las personas que no tienen un empleo formal, tienen un ingreso menor a los \$25,000. Asimismo, se muestra que las personas que más contestaron corresponden a las que se dedicaron a hacer

quehaceres domésticos. Esto no es un trabajo altamente remunerado por lo que se explica que el ingreso sea menor a los \$25,000. Por otro lado, se muestra un gran número de encuestados que no contestaron esta sección y se podrían considerar como los que sí cuentan con un empleo.




Gráfico 10. Motivos de no trabajo por umbral de ingreso

Por otro lado, el Gráfico 11 muestra las horas que dedicaron los encuestados a trabajar la semana pasada. Entre las posibles respuestas estaba: no recuerda (8), no lo hizo (9). Los que sí trabajaron la semana pasada se muestran a través de la primera barra en el gráfico, sin embargo, no se especifica el número de horas. En este caso, se muestra una proporción ligeramente mayor para los que ganan menos de \$25,000. Por otro lado, los encuestados que no trabajaron la semana pasada, tienen una gran diferencia de ingreso en donde la mayoría gana menos de \$25,000. No hay encuestados que no recuerden las horas trabajadas la semana pasada.




Gráfico 11. Distribución de horas trabajadas la semana pasada por umbral de ingreso

En el *Gráfico 12* se muestra una comparativa de ingresos entre las personas que tienen alguna discapacidad (variable que fue construida anteriormente). Se muestra una mayor igualdad para los que no tienen alguna discapacidad en cuanto al ingreso, sin embargo, no se llega a un 50-50. A través de esta gráfica se puede apreciar que las personas con alguna discapacidad física son más propensas a tener un ingreso desigual que otras personas con la misma capacidad mental.




Gráfico 12. Frecuencia de personas con discapacidad por umbral de ingreso

El *Gráfico 13* permite observar que no hay una diferencia significativa entre las personas que cuentan con un problema de salud y las que no. En ambos casos, las personas encuestadas son más propensas a ganar menos de \$25,000. A través de esta gráfica se puede inferir que el tener un problema de salud no es problema en México para ser contratado y no tiene un impacto en el ingreso de las personas. Por el contrario, se refleja una disparidad general en el ingreso de los mexicanos que se puede deber a otros motivos.




Gráfico 13. Frecuencia de personas con problemas de salud por umbral de ingresos

Finalmente, el *Gráfico 14* muestra que las personas que se consideran indígenas (1) presentan una mayor desigualdad en el ingreso que las personas no se consideran indígenas (2). Casi el 80% de los encuestados que se consideran indígenas tienen un ingreso menor a \$25,000. Esta proporción podría reflejar una desigualdad de oportunidades entre las culturas mexicanas, sin embargo, también es importante relacionar otros aspectos como la educación, el tipo de trabajo, la entidad, entre otros.




Gráfico 14. Frecuencia de personas por etnia por umbral de ingreso

Identificación de tendencias, patrones y posibles valores atípicos

Con el análisis bivariado se lograron identificar algunas tendencias y patrones. Los hombres son más propensos a tener ingresos igual o superior a los 25k. En cuanto al ingreso por entidad, la mayoría de las entidades tienen una mayor proporción de individuos con ingresos menores a 25k. Los encuestados con una edad entre los 30 y 39 años son los que más tienden a tener ingresos por encima del umbral establecido. Además, conforme aumenta la edad (después de los 30 años), la probabilidad de tener un ingreso menor a 25k aumenta. En contraste, entre más aumenta el nivel escolar de la personas, es más probable que esta tenga ingresos iguales o superiores al umbral.

Otro aspecto importante es la presencia de alguna discapacidad, pues las personas con alguna discapacidad física son más propensas a tener un ingreso desigual que otras personas con la misma capacidad mental. Por último, destacó que las personas que se consideran indígenas tienden a tener ingresos por debajo del umbral, en comparación con las personas no se consideran indígenas. Por otro lado, en la variable 'usotiempo1' no se describió un comportamiento relevante que nos permita saber las horas que se invierten en el trabajo y que se relacionan al estudio de la percepción de ingreso, por lo que se considera no significativa para el estudio. Además, en el Gráfico 10 de la variable 'act_pnea1' se muestra que la mayoría de los

encuestados no contestaron esta pregunta, por lo que esta variable no sería representativa para la mayoría de la población y, por ende, no es relevante para el estudio.

Por otro lado, se vieron algunos valores atípicos en nuestra base de datos. Por ejemplo, se encontraron usuarios que tienen ingresos iguales o mayores a \$25,000 trimestrales con una edad mucho menor a 18 años. Esto habla de un comportamiento fuera de lo común en nuestros datos. Similarmente, en la variable de la edad se encontraron usuarios con edades de 0 años, lo cual impacta el comportamiento de tendencias y, por ende, el análisis y el modelo final.

B. Data Cleaning

Para empezar a manipular y descubrir los insights que nos proporcionan los datos del INEGI, es necesario realizar una limpieza de los datos. Para ello, el equipo decidió llevar a cabo ciertas acciones para eliminar, modificar o complementar la información. Primero, importamos el archivo CSV y realizamos una visualización general de los datos. Observamos que la mayoría de los datos se mostraban como cadenas de texto (object), por lo que convertimos estos datos a formato numérico durante la importación, facilitando así su manipulación y eficiencia.

Una vez hecho esto, analizamos la estructura de los datos mostrando los valores de las distintas características del DataFrame. En esta previsualización, notamos que las edades de las personas con ingresos considerables abarcaban desde los 0 hasta más de 100 años. Por lo tanto, decidimos limitar las edades a partir de los 18 años. También observamos una variable que indicaba si las personas habían trabajado el mes anterior. Dado que solo nos interesaban aquellas personas con remuneración económica, decidimos eliminar los datos de las personas que no tenían trabajo. Además, eliminamos variables que no consideramos significativas o relevantes para el análisis bivariado.

Posteriormente, notamos muchos espacios vacíos en la base de datos. Escribimos una línea de código para reemplazar estos espacios en blanco por valores nulos, lo cual facilitó la posterior eliminación de estos valores, que solo añadían ruido al análisis. Una vez hecho esto, eliminamos los valores nulos, excluyendo a las personas sin un registro válido en el dataset. Por ejemplo, eliminamos los valores nulos de cualquier columna, evitando así considerar a personas con datos incompletos.

Además, detectamos algunas características con valores que igual solo introducían ruido en los gráficos, como 'nivelaprob', que contenía datos irrelevantes. Para resolver este problema, reemplazamos estos valores extras con el valor más común de esa característica. Por ejemplo, en la columna 'nivelaprob', cambiamos los valores por un '1', justificando esta decisión con una gráfica de barras que mostraba un comportamiento similar al umbral de los datos adicionales. Concluyendo, consideramos que la base de datos estaba lista para iniciar el proceso de “Data Engineering”, permitiendo una estructuración y organización adecuada de la información para una manipulación y visualización eficiente de los datos.

C. Data Engineering

Como se mencionó anteriormente, se contaba con numerosas variables, por lo que se tomaron decisiones sobre cuáles conservar para mejorar el análisis del estudio. Estas decisiones de data engineering se tomaron con el objetivo de mantener las variables que consideramos relevantes para la predicción óptima que deseamos realizar. Al escoger las variables pertinentes, se vuelve más fácil trabajar de manera enfocada hacia nuestros objetivos de proyecto.

Dentro de estas decisiones, se optó por mantener variables como la edad, el sexo, el estado conyugal, la entidad del usuario, el nivel educativo y la etnia. Asimismo, se incluyeron variables relacionadas con la cantidad de hijos sobrevivientes y fallecidos para calcular el número total de hijos de una persona. Además, se añadió una variable para indicar si la persona posee alguna discapacidad; dicha transformación se explica más adelante. Todas estas variables son fundamentales para describir la vida de cada usuario.

Asimismo, se conservaron variables relacionadas con la salud, como si la persona tiene algún problema de salud y si pertenece al INSABI o al seguro popular. Esto nos permitirá analizar cómo las condiciones médicas pueden afectar significativamente los ingresos de una persona en el último mes, ya que las condiciones médicas pueden limitar considerablemente a muchos trabajadores en sus áreas respectivas. Es importante mencionar que también se mantuvieron variables de identificación de datos para asegurar la integridad del análisis.

Posteriormente, se añadieron variables como la cantidad de horas trabajadas durante la semana pasada, si trabajó durante el mes anterior, el número de empleos que tiene, el ingreso trimestral total, la relación entre el ingreso trimestral máximo y total, y si es asalariado (más

adelante se explica el cálculo de estas últimas dos variables). De esta manera, buscamos tener variables relacionadas con el tiempo dedicado al trabajo, la cantidad de empleos y la remuneración obtenida para predecir la percepción de ingresos de una persona.

Con la base de datos seleccionada, se prepararon los datos y se realizaron varias transformaciones. Primero, se filtraron los datos para eliminar los registros de personas menores de 18 años, asegurando que solo se consideren adultos en el análisis. Esto se hizo considerando que, antes de los 18 años (la edad legal), la participación económica es mínima. Luego, se eliminaron los registros de personas desempleadas, centrándonos únicamente en la población activa, dado que sin trabajo no hay ingresos. Adicionalmente, se unificaron las diversas categorías de discapacidades en una única variable binaria que indica si una persona tiene o no alguna discapacidad, facilitando así el análisis y la interpretación de los datos.

Además, se introdujo una nueva columna llamada 'ratio', que calcula el ingreso trimestral máximo como una proporción del ingreso trimestral total. Este indicador nos ayuda a comprender la significancia del ingreso máximo de cada persona en relación con el total, ofreciendo una perspectiva valiosa sobre la distribución de ingresos dentro de nuestra muestra. El siguiente paso fue introducir otra columna llamada 'es_asalariado', derivada de la columna 'clave_max'. Esta nueva variable permite una evaluación detallada de las diferencias en las condiciones laborales y económicas entre asalariados y no asalariados, ayudándonos a comprender las dinámicas del mercado laboral. Por último, se normalizaron los datos para asegurar que todas las variables se encuentren en una escala comparable, mejorando la precisión y coherencia del análisis.

En cuanto a las técnicas utilizadas para la manipulación y transformación de datos, se empleó el filtrado de datos para excluir registros irrelevantes con base en criterios de edad y situación laboral. Para la agrupación de discapacidades, se aplicaron técnicas de codificación binaria, transformando múltiples categorías en una representación simplificada y coherente. Por otra parte, se realizó una transformación en la variable 'ratio'. Esta variable fue redondeada a la décima más cercana y posteriormente convertida en un indicador binario, diferenciando si todos los ingresos del trimestre provienen de un solo pago o no, lo que facilita el estudio sobre la estabilidad y regularidad de los ingresos. Además, se clasificó a los individuos según su tipo de ingreso con la columna 'es_asalariado', asignando el valor de 1 si su principal fuente de ingreso

es asalariada, y un valor de 2 para aquellos con otras fuentes de ingresos. La normalización de datos se realizó aplicando técnicas de escalado para ajustar las variables a una misma escala. Finalmente, se realizaron análisis de correlación de datos para identificar relaciones significativas entre las variables.

A continuación se muestran las variables que consideramos más relevantes para la identificación de patrones en el comportamiento de los datos (*Tabla 1*). Cabe mencionar que las primeras tres variables serán excluidas del análisis y solo serán utilizadas para desplegar los datos, ya que estas variables representan un código de identificación personal.

Variable	Tipo de dato	Significado
folio viv	Numérico	Identificador de la vivienda
foliohog	Numérico	Identificador del hogar
numren	Numérico	Identificador de la persona
sexo	Categorico	1 - Hombre 2 - Mujer
edad	Numérico	Edad del encuestado
nivelaprob	Categorico	Nivel de instrucción aprobado 0 - Ninguno 1 - Preescolar 2 - Primaria 3 - Secundaria 4 - Preparatoria o Bachillerato 5 - Normal 6 - Carrera técnica o comercial 7 - Profesional 8 - Maestría 9 - Doctorado
edo_conyug	Categorico	Situación conyugal 1 - Vive con su pareja en unión libre 2 - Está casado 3 - Está separado 4 - Está divorciado 5 - Es viudo 6 - Está soltero
hor_1	Numérico	Horas de trabajo
prob_sal	Categorico	Problemas de salud

		1 - Sí 2 - No
trabajo_mp	Categorico	Trabajó el mes pasado 1 - Sí 2 - No
num_trabaj	Numérico	Número de trabajos
entidad	Categorico	Entidad federativa 1 - Aguascalientes 2 - Baja California 3 - Baja California Sur 4 - Campeche 5 - Coahuila de Zaragoza 6 - Colima 7 - Chiapas 8 - Chihuahua 9 - Ciudad de México 10 - Durango 11 - Guanajuato 12 - Guerrero 13 - Hidalgo 14 - Jalisco 15 - México 16 - Michoacán de Ocampo 17 - Morelos 18 - Nayarit 19 - Nuevo León 20 - Oaxaca 21 - Puebla 22 - Querétaro 23 - Quintana Roo 24 - San Luis Potosí 25 - Sinaloa 26 - Sonora 27 - Tabasco 28 - Tamaulipas 29 - Tlaxcala 30 - Veracruz de Ignacio de la Llave 31 - Yucatán 32 - Zacatecas
etnia	Categorico	Autoadscripción étnica 1 - Sí 2 - No
umbral	Categorico	Umbral del ingreso trimestral total ≥ \$25,000 < \$25,000

ratio	Numérico	Proporción del ingreso trimestral total y el ingreso trimestral máximo
pop_insabi	Categorico	Seguro Popular / INSABI 1 - Sí 2 - No
hijos_sob	Numérico	Hijos sobrevivientes
hijos_mue	Numérico	Hijos fallecidos
alguna_discapacidad	Categorico	1 - Sí 2 - No
es_asalariado	Categorico	Es asalariado 1 - Sí 2 - No
ing_tri_total	Numérico	Ingreso trimestral total

Tabla 1. Descripción de las variables consideradas

A continuación se muestra la matriz de correlaciones realizada para analizar las variables con mayor relación al ingreso de una persona (*Figura 1*). En la matriz se muestran correlaciones positivas para las relaciones directamente proporcionales y negativas para las inversamente proporcionales. La matriz no considera variables relacionadas a la cantidad de ingreso ya que son la base de lo que se busca predecir. Tampoco considera las variables relacionadas a la cantidad de hijos ya que estas solo son contabilizadas para las mujeres y se desea hacer una predicción para la población en general.

	sexo	edad	nivelaprob	edo_conyug	hor_1	prob_sal	trabajo_m_p	num_trabaj	entidad	etnia	pop_insabi
sexo	1	0.026346	0.002434	0.076752	-0.065794	-0.01922	0.218074	-0.194238	0.011453	-0.004929	-0.047845
edad	0.026346	1	-0.301338	-0.095302	-0.102321	-0.03484	0.26795	-0.21846	0.009693	-0.018315	-0.019696
nivelaprob	0.002434	-0.301338	1	0.109182	0.044232	-0.03933	-0.153177	0.111666	-0.017347	0.135309	0.142958
edo_conyug	0.076752	-0.095302	0.109182	1	-0.055097	-0.007466	0.05431	-0.064451	-0.010589	0.042957	0.048586
hor_1	-0.065794	-0.102321	0.044232	-0.055097	1	0.032714	-0.540302	0.519943	0.007835	-0.05016	-0.017257
prob_sal	-0.01922	-0.03484	-0.03933	-0.007466	0.032714	1	-0.017238	0.024884	0.009548	-0.042715	-0.010618
trabajo_m_p	0.218074	0.26795	-0.153177	0.05431	-0.540302	-0.017238	1	-0.867126	0.008733	0.011597	-0.038044
num_trabaj	-0.194238	-0.21846	0.111666	-0.064451	0.519943	0.024884	-0.867126	1	0.00732	-0.051582	0.01297
entidad	0.011453	0.009693	-0.017347	-0.010589	0.007835	0.009548	0.008733	0.00732	1	-0.121179	-0.01671
etnia	-0.004929	-0.018315	0.135309	0.042957	-0.05016	-0.042715	0.011597	-0.051582	-0.121179	1	0.069338
pop_insabi	-0.047845	-0.019696	0.142958	0.048586	-0.017257	-0.010618	-0.038044	0.01297	-0.01671	0.069338	1

Figura 1. Matriz de correlación de las 12 variables seleccionadas para el modelo ya que se excluyen las de identificación personal

La matriz de correlación muestra las relaciones entre las variables seleccionadas para el análisis. Los valores de correlación oscilan entre -1 y 1, donde un valor de 1 indica una correlación positiva perfecta, -1 indica una correlación negativa perfecta y 0 indica ninguna correlación. En esta matriz, ninguna variable muestra una correlación extremadamente alta (cercana a 1) o extremadamente baja (cercana a -1), lo que sugiere que las variables seleccionadas no tienen relaciones lineales muy fuertes entre sí. No obstante, hay algunas correlaciones que destacan y deben interpretarse para conocer su relevancia para el presente trabajo.

Por ejemplo, las variables ‘trabajo_mp’ y ‘num_trabaj’ tienen una alta correlación negativa (-0.867126). Esto indica una relación inversamente proporcional: a medida que una persona tiene más trabajos, es menos probable que haya trabajado el mes pasado, y viceversa. Esta relación podría parecer incoherente al principio, pero cobra sentido al considerar los valores que puede tomar cada variable (ver *Tabla 1*). En este caso, un valor de 1 en ‘trabajo_mp’ indica que la persona trabajó el mes pasado, por lo que, con más trabajos, es menos probable que esta variable tenga un valor de 2 (indicando que no trabajó el mes pasado). Una relación similar se observa entre ‘trabajo_mp’ y ‘edad’ (-0.540302). Ambas correlaciones reflejan más los valores asignados a cada variable que la naturaleza de las mismas.

La correlación entre ‘nivelaprob’ y ‘edad’ (-0.301338) también destaca si se trata de analizar intuitivamente. Esta correlación negativa sugiere una tendencia educativa donde las generaciones más jóvenes completan niveles más altos de educación. Nuevamente se está comparando una variable numérica con una categórica transformada a numérica. Considerando el contexto educativo en México en las últimas décadas, esta correlación negativa es destacable aunque no sea muy alta. Con base en el conjunto de datos tratado, esta relación puede provenir del rango establecido para la variable ‘edad’. Esta se limitó a solo considerar a mayores de edad (>18 años), pero también considera a gente de edad muy alta (como 109 años, la edad máxima). Esta correlación podría volverse más intuitiva si se establece un límite superior a la edad, excluyendo a las personas jubiladas.

Por otro lado, la correlación entre ‘num_trabaj’ y ‘hor_1’ es de 0.519943, una correlación positiva moderada que indica que a mayor número de trabajos, más horas trabaja una persona.

Esto es intuitivo, ya que tener múltiples trabajos generalmente implica trabajar más horas en total. De manera similar, aunque con una correlación más baja, se observa una relación positiva entre 'trabajo_mp' y 'sexo' (0.218074). Esta débil correlación sugiere que los hombres tienen una ligera mayor probabilidad de haber trabajado el mes pasado en comparación con las mujeres. Aunque la relación no es fuerte, esta implicación es coherente con el contexto laboral en México, donde existe una desigualdad de género que generalmente favorece a los hombres.

Aunque muchas correlaciones no son extremadamente fuertes, las relaciones identificadas proporcionan información valiosa sobre las dinámicas laborales y sociodemográficas de la población analizada. Estos insights son útiles para realizar inferencias y tomar decisiones informadas con base en los datos obtenidos. La lista de variables elegidas por orden de correlación con el ingreso trimestral total se pueden encontrar en los Anexos como la *Tabla 1*.

Al concluir el procesamiento y la experimentación de los datos, nuestra base de datos terminó con 180,583 registros y las variables seleccionadas. No hay presencia de valores nulos en nuestra base de datos, así como la mayoría de nuestras variables son números enteros, aunque algunas son de tipo flotante o booleano. También es importante aclarar que nuestras clases se quedaron con la misma cantidad de datos en cada una de nuestras variables. Esto asegura una distribución equilibrada de datos en cada una de nuestras variables, proporcionando una base de datos bien fundamentada y robusta para el análisis.

IV. Modelado

A. Modelo de Árboles de decisión

En el campo de los modelos de predicción, existen varios métodos bien conocidos que permiten analizar bases de datos y predecir valores específicos. Uno de estos métodos es el modelo de árboles de decisión, un modelo de aprendizaje automático que utiliza variables como condicionales para tomar decisiones.

Un árbol de decisión consta de nodos, que se seleccionan en función de nuestras variables. En cada nodo se formula una "pregunta" que ayuda a dividir los datos de manera efectiva, asignando una rama a un nuevo nodo, lo cual permite continuar el proceso de predicción del valor objetivo. En este caso, utilizamos varias de las variables previamente mencionadas y establecimos el umbral como objetivo. El modelo de árboles de decisión es intuitivo y fácil de interpretar, lo que nos permite visualizar el comportamiento de cada nodo y sus respectivas ramas de decisión tanto en predicciones de clasificación como en regresión.

El proceso se basa en la utilización de bases de datos de entrenamiento y prueba. Entrenamos el algoritmo con un conjunto de datos y luego lo probamos con una base de datos que representa el 20% de los datos totales en el área de prueba. Los modelos de árboles de decisión tienen parámetros que determinan cómo se entrena el algoritmo, influyendo en la división de nodos, la selección de datos, la profundidad del árbol y la cantidad de muestras, entre otros aspectos. Todos estos parámetros son ajustables para optimizar el rendimiento del modelo.

En el presente trabajo, se utiliza un modelo de árbol de decisión para clasificar a los usuarios según si están por debajo o por encima del umbral de ingreso trimestral de \$25,000 MXN. Asimismo, experimentamos con la predicción de ingresos mediante regresión, buscando estimar el salario de cada individuo en los datos.

B. Metodología

Tras finalizar la limpieza de los datos y trabajar con un solo dataset, iniciamos la separación de los datos de entrenamiento y los datos de prueba. En este caso, separamos en variables “y” y “X”, siendo la “y = ing_tri_total” y $X = ['sexo', 'edad', 'nivelaprob', 'edo_conyug', 'hor_1', 'prob_sal', 'num_trabaj', 'entidad', 'etnia', 'pop_insabi', 'hijos_sob', 'hijos_mue',$

'alguna_discapacidad', 'es_asalariado']. Ya con estos datos podemos separar ambas variables para crear cuatro variables: 'X_train', 'X_test', 'y_train' y 'y_test'. Es importante mencionar que, durante la creación de los subconjuntos de entrenamiento y prueba, se mantuvo una proporción de 80/20.

a. Experimentos

Para conocer el rendimiento del entrenamiento de los datos, el equipo decidió realizar una serie de modelos que nos permitieran identificar la existencia de patrones para la posible predicción de la información. A continuación, se muestra la eficiencia del modelo simple junto con tres variaciones del mismo, esperando encontrar aquel modelo que más se acerque al ajuste perfecto de los datos.

i. Modelo simple

A partir del umbral de los ingresos, dividimos los datos en subconjuntos de entrenamiento y de prueba, obteniendo 144,466 registros para el conjunto de entrenamiento y 36,117 registros para el conjunto de prueba. Con esta distribución de los datos, realizamos la primera clasificación con un árbol de decisión, obteniendo una exactitud del 69% basada en los datos de prueba, lo que indica que hay un 69% de probabilidad de que la predicción sea correcta. Tras completar este modelo, realizamos ajustes en otros modelos para evaluar si podían ofrecer una mejor interpretación de los datos.

	Precisión	Recall	Accuracy	F1-Score
Árbol de decisión sin GridSearch	0.55409172	0.55082946	0.6856604922	0.552414

Tabla 2. Métricas de rendimiento del modelo de Árbol de decisión sin GridSearch

Observando las métricas de rendimiento obtenidas para el modelo de Árbol de decisión sin GridSearch (*Tabla 2*), podemos concluir que el modelo simple generado no es adecuado para

hacer predicciones. Aunque muestra un valor de exactitud aceptable, las demás métricas tienen valores cercanos al 50%, lo que evidencia una deficiencia en el rendimiento del modelo.

ii. Modelo optimizado

Uno de los ajustes realizados para mejorar el rendimiento del modelo fue implementar una búsqueda con GridSearch para encontrar los mejores hiper parámetros. A partir de ella, se realizó un nuevo árbol de decisión con los hiper parámetros encontrados como base, los cuales fueron los siguientes:

- Medida de impureza para evaluar las divisiones de nodo: *Gini*
- Profundidad máxima permitida del árbol: 7
- Muestras mínimas necesarias en un nodo hoja: 4
- Muestras mínimas necesarias para dividir un nodo: 2

GridSearch nos proporcionó los parámetros que nuestro modelo debe tener en cuenta para estar optimizado y obtener las mejores métricas posibles. En el proceso de GridSearch, se generan permutaciones de las combinaciones de cada uno de los hiperparámetros y, mediante métricas de evaluación, se determinan los mejores parámetros.

	Precisión	Recall	Accuracy	F1-Score
Árbol de decisión con GridSearch	0.73899308	0.7461860065	0.7461860065	0.7363155098

Tabla 3. Métricas de rendimiento del modelo de Árbol de decisión con GridSearch

Como se puede apreciar en la *Tabla 3*, las métricas de precisión y exactitud mejoraron en gran medida en comparación con el modelo simple. Por una parte, podemos observar que la precisión del modelo asciende a casi 0.74, lo que indica que el 74% de las veces que el modelo dice que la persona se encuentra por encima del umbral de 25 mil pesos, es correcto. Por otro lado, vemos que la exactitud indica que el modelo es capaz de acertar el 74.61% de las veces, lo cual es destacable al observar el anterior modelo. Ahora bien, las métricas del Recall y el F1-Score salieron favorables para el rendimiento del modelo con un 0.74 y un 0.73 respectivamente, lo que

nos indica que el modelo cuenta con una buena capacidad para identificar correctamente las instancias positivas, manteniendo un balance adecuado entre precisión y sensibilidad.

iii. Modelo opt. con oversampling

Después de optimizar el árbol, no se observó una mejora significativa en las métricas, por lo que exploramos otras áreas de oportunidad. Dado que las muestras de las clases estaban desbalanceadas, se aplicó un método de oversampling para mejorar el modelo. Utilizamos la librería imblearn para aumentar el número de muestras en la clase minoritaria y equilibrarla con la clase mayoritaria. El método `ros.fit()` ajusta los datos mediante un estado aleatorio, creando nuevos conjuntos de datos de entrenamiento y prueba. Posteriormente, el árbol de decisión realizó la clasificación con estos nuevos conjuntos. Para obtener un mejor rendimiento de este nuevo modelo, realizamos una búsqueda de los mejores hiperparámetros con GridSearch, obteniendo los siguientes:

- Medida de impureza para evaluar las divisiones de nodo: *Entropía*
- Profundidad máxima permitida del árbol: *None*
- Muestras mínimas necesarias en un nodo hoja: 1
- Muestras mínimas necesarias para dividir un nodo: 2

Estos hiperparámetros permitieron evaluar el comportamiento del modelo y asignar el análisis de las variables de manera óptima. El ajuste de las variables balanceadas significó que la profundidad del árbol ya no era una limitación.

	Precisión	Recall	Accuracy	F1-Score
Árbol de decisión optimizado con Oversampling	0.6877687727	0.6882631447	0.6882631447	0.6880117718

Tabla 4. Métricas de rendimiento del modelo de Árbol de decisión optimizado con Oversampling

Al observar los resultados, notamos que el rendimiento del modelo empeoró en comparación con el anterior. Todas las métricas mantuvieron un valor de 0.68, indicando un rendimiento moderado y consistente. Sin embargo, al comparar este modelo con el anterior, concluimos que su

rendimiento es inferior y no sería adecuado para determinar si una persona se encuentra por encima o por debajo del umbral de los 25 mil pesos.

iv. Modelo opt. con undersampling

Para este nuevo modelo de clasificación, realizamos diferentes ajustes a los datos. Dado que las muestras de las clases estaban desbalanceadas, decidimos aplicar un método de undersampling para mejorar el modelo. Nuevamente utilizamos la librería imblearn, pero en este caso para reducir el número de muestras en la clase mayoritaria y equilibrarla con la clase minoritaria. El método de undersampling ajusta los datos mediante un estado aleatorio, permitiendo la creación de nuevos conjuntos de datos de entrenamiento y prueba para volver a realizar la clasificación con estos conjuntos.

Para mejorar el rendimiento del modelo, realizamos una búsqueda de los mejores hiperparámetros con Grid Search, obteniendo los siguientes:

- Medida de impureza para evaluar las divisiones de nodo: *Entropía*
- Profundidad máxima permitida del árbol: 7
- Muestras mínimas necesarias en un nodo hoja: 4
- Muestras mínimas necesarias para dividir un nodo: 10

Estos hiperparámetros permitieron observar un comportamiento específico de los datos. Al aplicar el undersampling, pretendíamos reducir el sesgo introducido por la clase mayoritaria, generando las siguientes métricas de evaluación.

	Precisión	Recall	Accuracy	F1-Score
Árbol de decisión optimizado con Undersampling	0.74038179430	0.727635185646	0.72763518564	0.7316010901

Tabla 5. Métricas de rendimiento del modelo de Árbol de decisión optimizado con Undersampling

Al analizar las métricas de este último modelo de clasificación, observamos que el rendimiento del clasificador es consistente, similar al modelo con oversampling, pero con evaluaciones más altas. En general, esto indica que el modelo es aceptable. Sin embargo, al comparar este modelo

con el modelo simple optimizado, nos damos cuenta de que su rendimiento es ligeramente inferior, lo que confirma que el segundo modelo es el mejor para predecir la clasificación del umbral de los datos.

v. XG Boost

Para concluir el análisis, decidimos probar el modelo XGBoost, ya que se basa en árboles de decisión, pero además utiliza el gradiente descendente y el boosting para mejorar los resultados obtenidos. Este modelo es recomendable para obtener mayor precisión y manipular grandes cantidades de datos. Dado que era necesario mejorar estos aspectos, implementamos XGBoost. La mejora del modelo es claramente observable en los resultados obtenidos (*Tabla 6*), los cuales fueron los mejores que hemos logrado hasta el momento.

	Precisión	Recall	Accuracy	F1-Score
XGBoost Classification	0.7610620476446	0.7664811584572	0.7664811584572	0.7605405180677

Tabla 6. Métricas de rendimiento del modelo de XGBoost Classification

vi. Random forest para predecir el salario

Como último modelo se decidió probar un Random Forest, aunque ya no para predecir si una persona está por encima o por debajo del umbral de los \$25,000 MXN. En vez, para este modelo se estableció el ingreso trimestral total como la variable objetivo. Es decir, ahora se está buscando generar un modelo capaz de predecir el salario de la persona. Cabe mencionar que se puso un límite de \$70,000 MXN, ya que no es común este salario arriba de este para un mexicano, por lo que habría muy pocas instancias en el modelo después de este valor.




Gráfico 15. Comparación valores reales vs predictores del Random Forest

Se puede observar en el *Gráfico 15* que la mayoría de las predicciones están dispersas y no se alinean estrechamente con la línea roja (la diagonal). Esto sugiere que el modelo tiene dificultades para predecir los salarios con alta precisión. Sin embargo, la concentración de puntos en las regiones inferiores del gráfico también refleja la distribución de los salarios en la base de datos, donde los salarios más altos son menos frecuentes.




Gráfico 16. Proporción de error de predicción del RF

Como podemos ver en el *Gráfico 16*, aunque la mayoría de los errores se concentran cerca de cero, también se observan errores significativos que alcanzan aproximadamente los \$2,000 MXN con una considerable frecuencia. Esto confirma que nuestra experimentación con el modelo Random Forest para predecir el salario, sin utilizar el umbral, fue poco precisa y no acertada. El rendimiento del modelo podría mejorarse si se trabajara con rangos, reduciendo así la complejidad de la tarea. De esta manera, se podrían manejar valores con menos dimensionalidades, facilitando alcanzar nuestro objetivo de predicción de manera más eficiente.

b. Métricas de desempeño

Para poder determinar si el modelo generado es bueno o no, es necesario entender y calcular las diferentes métricas de desempeño de los modelos: precisión, recall, accuracy (exactitud) y F1-Score. La precisión indica la proporción de verdaderos positivos sobre todos los positivos predichos; es decir, mide la exactitud de las predicciones positivas. Similarmente, el recall es la proporción de verdaderos positivos sobre todos los positivos reales. Esta métrica indica la capacidad del modelo para encontrar todos los positivos reales. El F1-Score es la media armónica de la precisión y el recall. Por último, el accuracy indica la proporción de todas las predicciones correctas (positivas y negativas) sobre el total de observaciones. Y estas métricas por nuestros modelos se enseñan a continuación.

C. Resultados

a. Resultados generales

Para poder determinar el modelo con el mejor rendimiento, es necesario comparar los modelos con base en las diferentes métricas de desempeño obtenidas. Para los siguientes pasos, se decide continuar únicamente con los árboles de decisión. Se toma esta decisión porque gracias a las múltiples modificaciones en los hiperparámetros y el balance de los datos se puede realizar una mejor comparativa del modelo. Sin embargo, aunque el modelo de XGBoost presentó mejores métricas y resultados, no se incluye en la comparativa ya que se desviaba del objetivo primordial

del proyecto. A continuación se muestra una tabla con la comparación de dichas métricas de los diferentes modelos generados.

	Precisión	Recall	Accuracy	F1-Score
Árbol de decisión sin GridSearch	0.55409172	0.55082946	0.6856604922	0.552414
Árbol de decisión con GridSearch	0.73899308	0.7461860065	0.7461860065	0.7363155098
Árbol de decisión optimizado con Oversampling	0.6877687727	0.6882631447	0.6882631447	0.6880117718
Árbol de decisión optimizado con Undersampling	0.74038179430	0.727635185646	0.72763518564	0.7316010901

Tabla 7. Comparación de las métricas de cada modelo

Con base en las interpretaciones de los resultados individuales y esta comparación de los mismos, es posible determinar que el árbol de decisión simple optimizado es el modelo con el mejor rendimiento general. Tiene la mayor exactitud, recall y F1-Score. Por consiguiente, se puede decir que el uso de GridSearch ayudó a mejorar varias métricas del modelo simple. Por otra parte, las técnicas de oversampling no mejoraron significativamente las métricas en comparación con el modelo básico sin GridSearch. Sin embargo, podemos observar que la técnica de undersampling si logró un buen rendimiento, pero no tan bueno como el simple optimizado con GridSearch. Entonces, si se busca tener un enfoque equilibrado, el modelo de árbol de decisión con GridSearch es la mejor opción, especialmente si se quiere identificar correctamente a aquellos mexicanos mayor a 18 años que están por encima o por debajo del umbral de ingreso trimestral de \$25,000 MXN.

b. Selección y validación cruzada del mejor modelo

En este modelo mejorado, se implementó la validación cruzada, lo que nos permitió dividir nuestros datos en pliegues de manera selectiva. Esto nos ayudó a evitar la dependencia de ciertos datos específicos y a obtener un modelo más generalizado. Al final, se promediaron las métricas

de rendimiento del modelo, lo que permitió identificar los siguientes parámetros óptimos para mejorar la predicción:

- Particiones de los datos “subsets”: 5
- Cantidad de veces que se entrenará el modelo por partición “k”: 4
- Cantidad de veces que se prueba el modelo por partición: 1

V. Evaluación del modelo seleccionado

A continuación se estará evaluando este modelo que tuvo el mejor rendimiento. Este utiliza GridSearch para optimizar la selección de hiperparámetros, así como la validación cruzada para evitar el sobreajuste y mejorar la generalización del modelo. Además, se seleccionó el 80% de los datos para el entrenamiento y el 20% para la prueba, siguiendo la práctica habitual. Los hiperparámetros seleccionados para este modelo fueron los siguientes:

- Medida de impureza para evaluar las divisiones de nodo: Gini
- Profundidad máxima permitida del árbol: 7
- Muestras mínimas necesarias en un nodo hoja: 4
- Muestras mínimas necesarias para dividir un nodo: 2

	Precisión	Recall	Accuracy	F1-Score
Árbol de decisión optimizado con Undersampling	0.74038179430	0.727635185646	0.72763518564	0.7316010901

Tabla 8. Métricas de rendimiento del modelo seleccionado

Además, los mejores valores obtenidos de la validación cruzada fueron los siguientes, lo que permitió evitar la dependencia de ciertos datos y mejorar el rendimiento del modelo:

- Particiones de los datos “subsets”: 5
- Cantidad de veces que se entrenará el modelo por partición “k”: 4
- Cantidad de veces que se prueba el modelo por partición: 1

A. Análisis de desempeño

A partir de las métricas y parámetros utilizados, podemos tener una visión más profunda del desempeño del modelo. La clasificación muestra una exactitud del 72.76% de las instancias, lo que nos indica que las personas que están por encima como por debajo del umbral propuesto son

clasificadas correctamente. Esta métrica es considerada como una medida global del desempeño del modelo, lo que nos indica que hay un buen nivel de predicción general.

Por otra parte, tenemos la precisión, la cual se muestra con un valor de 0.7404. Esto nos indica que cuando el modelo predice que una persona está por encima del umbral de 25 mil pesos, es correcto el 74.04% de las veces. Por consiguiente, también nos muestra una minimización de los falsos positivos, es decir, las situaciones en las que el modelo incorrectamente clasifica a alguien como si estuviera por encima del umbral.

Otra métrica a destacar es el recall, el cual se encarga de identificar correctamente los casos positivos del modelo. En este caso, el recall muestra un valor equivalente a 0.7276, lo que nos muestra que el modelo es capaz de identificar el 72.76% de las personas que realmente se encuentran por encima del umbral de 25 mil pesos trimestrales.

El F1 Score es una media basada en la precisión y el recall, esta métrica nos indica un balance entre identificar correctamente a las personas por encima del umbral y evitar clasificaciones incorrectas. El valor proporcionado a esta métrica es de 0.7316 lo que sugiere que es un valor aceptable para mostrar el desempeño del equilibrio mencionado.

Ahora bien, queríamos comprobar que los datos no tuvieran un sobreajuste en el aprendizaje de los datos, para ello utilizamos el método de la validación cruzada, el cual básicamente consiste en utilizar todos los datos de entrenamiento para comprobar que el aprendizaje del modelo está siendo adecuado y no se está arraigando específicamente a un solo aprendizaje, es decir, mediante el número de folds determinados, se pueden hacer pruebas aleatorias que se promedian para garantizar que el modelo funcionará bien en datos no vistos, garantizando que el modelo funcione sin sesgo a datos que podrían implicar en algún momento un sobreajuste. En el caso de nuestro modelo, las puntuaciones de la validación cruzada son consistentes, lo que nos indica que el modelo tiene un buen desempeño de forma general y no está sobreajustado a los datos de entrenamiento.

Si mencionamos las métricas distintivas, es importante nombrar también el Área Bajo la Curva o AUC, el cual muestra un valor de 0.6937, lo que sugiere que el modelo tiene un desempeño aceptable en términos de diferenciación de las personas que se encuentran por encima de los 25 mil pesos trimestrales y las que no. Sin embargo, es importante mencionar que fue el valor más bajo de desempeño que se consiguió, por lo que nos indica que hay una amplia área de mejora para el modelo en general.




Figura 2. Matriz de confusión

- Verdaderos Positivos: 6569 personas correctamente clasificadas por encima del umbral
- Falsos Positivos: 3019 personas incorrectamente clasificadas por encima del umbral
- Verdaderos Negativos: 20379 personas correctamente clasificadas por debajo del umbral
- Falsos Negativos: 6150 personas incorrectamente clasificadas por debajo del umbral.

Los valores de la matriz de confusión respalda lo que anteriormente se había establecido con la precisión y el recall, determinando que el modelo es simplemente bueno para la clasificación correcta de las instancias.

Mediante estas métricas de desempeño, podemos determinar que el modelo tiene un buen rendimiento para predecir si una persona está por encima del umbral de 25 mil pesos trimestrales. Se puede visualizar que el AUC indica que hay todavía un gran margen para mejorar la capacidad del modelo, sin embargo, la matriz de confusión confirma que el modelo tiene buena tasa de verdaderos positivos y verdaderos negativos, lo que justifica que es buen modelo de clasificación.

B. Análisis de características importantes

Después de realizar nuestro análisis mediante árboles de decisión y seleccionar cual de ellos fue el mejor modelo, observamos cuales son las características más importantes para el resultado arrojado por el árbol. En este caso el árbol con mejor rendimiento fue el modelo simple con los mejores hiper parámetros. Para este árbol las características más importantes son 'nivel_aprob', 'sexo' y 'edad'. En este caso la relación más importante en el modelo por gran diferencia es la variable de nivel_aprob. Desde nuestro análisis bivariado habíamos observado que había una gran relación entre el nivel de estudio alcanzado y el ingreso trimestral total. Esta variable es nuestro nodo raíz y es separada si el nivel aprobado es mayor 0.4555 (dato normalizado). Seguido de esto los datos de Sexo y Edad tienen peso sobre la separación pero es muy alta la diferencia que hay entre la importancia de Nivel_aprob y estas dos variables.




Figura 3. Árbol de decisión que muestra las características más importantes.

C. Implicaciones y limitaciones del modelo y su uso

Nuestro modelo de predicción binaria antes mencionado tiene implicaciones como sería la ética de poder tener posesión del uso de dicho modelo. Pues al poder predecir si una persona estará abajo o arriba de un sueldo. Puede tener implicaciones en el uso que se le puede dar. Se tiene que tener en cuenta que este modelo es para poder experimentar y poder tener un modelo que pueda

ayudar a organizaciones como sería el INEGI para así poder tener un estimado a futuro con base en las variables de usuarios.

También el modelo posee limitaciones, pues se escogió el modelo de decisión tree. Como podría ser el que se tenga un problema en momento de modelar con un gran cantidad de datos. Aunque en el problema antes mencionado no se cuenta con una base de datos enorme, si se tiene una gran cantidad de datos. Y modelos de este tipo al momento de interpretar tantos datos se ocupa bastante tiempo computacional. También este tipo de modelo tiene inestabilidad. En estos modelos al cambiar en algún aspecto los datos seleccionados cambia en gran manera la sensibilidad de nuestro modelo.

Esto nos lleva a que nuestro modelo en sí es una limitación, pues al nosotros no comparar con otros modelos como podría ser una red neuronal o SVM. Que nos daría una oportunidad de poder encontrar una mejor forma de poder llegar a nuestro objetivo y ver si el rendimiento es óptimo. Y esto nos encasilla a usar solo este modelo para poder llegar a nuestro objetivo.

Otra limitante fueron las variables que se tenían, al principio se poseía con muchas más variables y se redujo como se mencionó anteriormente. Pero la limitante siempre serán las variables que se poseen. Pues no sabemos si el poder tener la información adicional como sería por ejemplo de si el usuario fue a estudiar la primaria pero tener acceso a ¿cual? Y en qué ranking está situada esa educación primaria que se tuvo. Cual no se sabe si al tener esta información ayudará de gran manera el poder tener un mejor predictor. Como también nuestra limpieza de datos sería otra área de mejora. Nuestra selección que se comentó antes fue subjetiva, y esto afecta de manera directa el rendimiento de un modelo. Pues también por ejemplo una limitante que se piensa útil sería el poder eliminar a personas de 65 años para adelante en nuestra base de datos. Pues al nosotros tener usuarios que tienen a ser algo difícil el poder predecir su ingreso por cuestiones de ambigüedad en su vida. Altera por ejemplo nuestra correlación de las variables. Otra limitante es el cómo se codificaron las variables, como fueron seleccionadas las opciones proporcionadas en el cuestionario. Pues el acomodo de ellas afecta en cómo podemos interpretar y generar el predictor.

VI. Conclusiones

Los resultados de nuestro análisis exploratorio muestran una comprensión del comportamiento de las variables dentro de nuestra base de datos y su correlación con la variable objetivo de ingreso trimestral. Posteriormente, se realizó una selección de modelo de clasificación y regresión para modelar comportamientos relacionados al ingreso de un mexicano. Se analizaron varios modelos de árboles de decisión de clasificación para predecir si el ingreso de un mexicano está por encima o por debajo de \$25,000 pesos mexicanos por un periodo trimestral. Se obtuvo que el mejor modelo para describir este comportamiento fue el árbol de decisión optimizado con GridSearch ya que las métricas de evaluación fueron mejores por lo que el modelo tuvo mayor desempeño de predicción. Sin embargo, las métricas obtenidas podrían considerarse bajas ya que ninguna pudo llegar al 80% de desempeño pues todo modelo tiene sus límites ya que nunca puede ser mejor a la calidad de los datos que se tiene. Por otro lado, se realizó un modelo de regresión para predecir el ingreso exacto de una persona basado en características relevantes relacionadas a la persona. Este modelo obtuvo un rendimiento muy bajo ya que es complicado predecir con exactitud una cifra larga.

A través de varios modelos y la identificación de las 12 variables que tienen mayor impacto en el ingreso, se pudo visualizar que en este contexto, un modelo de clasificación es mejor para predecir el comportamiento de los datos. Además, fue esencial seleccionar el método que no solo maximizó la precisión general del modelo, sino que también logró minimizar tanto los falsos positivos como los falsos negativos. De este modo, se buscó optimizar el desempeño del modelo en la predicción de ingreso de los mexicanos para llevarlo a un caso de la vida real.

VII. Referencias

Fondo de Población de las Naciones Unidas. (14 de julio de 2023). *Población y Desarrollo*.

<https://mexico.unfpa.org/es/topics/poblaci%C3%B3n-y-desarrollo-2#:~:text=El%20INEGI%20reporta%20con%20base,total%20de%20la%20poblaci%C3%B3n%2C%20respectivamente.>

Instituto Nacional de Estadística y Geografía. (14 de diciembre de 2023). *Encuesta Nacional de Ingresos y Gastos de los Hogares Estacional (ENIGH E) 2022*.

<https://www.inegi.org.mx/contenidos/saladeprensa/boletines/2023/ENIGH-E/ENIGH-E-2022.pdf>

Instituto Nacional de Estadística y Geografía. (16 de marzo de 2021). *Censo de Población y Vivienda 2020*.

<https://www.inegi.org.mx/programas/ccpv/2020/#:~:text=La%20periodicidad%20definida.,presente%20y%20prever%20el%20futuro.>

Instituto Nacional de Estadística y Geografía. (s.f.). *Quiénes somos*.

<https://www.inegi.org.mx/inegi/contenido/infoest.html#:~:text=Somos%20un%20organismo%20p%C3%ABlico%20aut%C3%B3nomo,nuestro%20pa%C3%ADs%20y%20ayudar%20a>

Ortega, C. (10 de abril de 2023). *Análisis bivariante: Qué es, tipos y ejemplos*. QuestionPro.

<https://www.questionpro.com/blog/es/analisis-bivariante/#:~:text=%C2%BFQu%C3%A9%20es%20el%20an%C3%A1lisis%20bivariante,intensidad%20y%20en%20qu%C3%A9%20direcci%C3%B3n.>

VIII. Anexos

Variable	Valor
ing_tri_total	1
es_asalariado	-0.2816
nivelaprob	0.2748
trabajo_mp	-0.2534
ratio	-0.2255
sexo	-0.2228
num_trabaj	0.21516
hijos_mue	-0.1461
pop_insabi	0.13804
alguna_discapacidad	-0.1314
etnia	0.1267
hor_1	0.09308
entidad	-0.07
propo_sal	-0.0539
edo_conyug	-0.0487
edad	-0.0202
hijos_sob	0.01267

Tabla 1. Variables elegidas por orden de correlación con el ingreso trimestral total